

Análise de Imagens de Sensoriamento Remoto

Fundamentos e Aplicações Iniciais

Bruno M. M. Vieira ¹ Prof. Dra. Daniela de O. Maionchi ¹

¹Federal University of Mato Grosso
PPGFA

7 de Julho de 2025

- 1 Introdução ao SAR
 - Características do Sinal SAR
 - Mecanismos de Espalhamento
 - A Redundância em Imagens Multiespectrais
- 2 Análise de Componentes Principais (PCA)
- 3 A Imagem como Matriz de Dados
 - Manipulação com NumPy
 - Cuidados e Casos Especiais
 - Normalização e Qualidade da Imagem

Roteiro da Apresentação

1 Introdução ao SAR

- Características do Sinal SAR
- Mecanismos de Espalhamento
- A Redundância em Imagens Multiespectrais

2 Análise de Componentes Principais (PCA)

3 A Imagem como Matriz de Dados

- Manipulação com NumPy
- Cuidados e Casos Especiais
- Normalização e Qualidade da Imagem

O que é SAR?

- **S**ynthetic **A**perture **R**adar (Radar de Abertura Sintética).
- Sensor **ativo**: emite seus próprios pulsos de energia (micro-ondas).
- Mede o sinal **retroespalhado** pela superfície.
- Funciona dia e noite, independente das condições climáticas (nuvens, chuva).

Interação com a Superfície

Dois tipos principais de reflexão:



Reflexão Especular

- Superfícies **lisas**.
- Sinal refletido para longe do sensor.
- Ex: lagos calmos, asfalto.

Reflexão Difusa

- Superfícies **rugosas**.
- Sinal espalhado em várias direções.
- Ex: florestas, áreas urbanas.

Interpretando Imagens SAR



Frequências e Bandas

- **Banda X (curta):** Alta resolução, pouca penetração. Ideal para monitoramento urbano e de gelo.
- **Banda C (média):** Uso versátil. Mapeamento global, detecção de mudanças.
- **Banda L (longa):** Boa penetração em vegetação. Ideal para estudos de biomassa e geofísica.
- **Banda P (muito longa):** Altíssima penetração. Usada em estudos de biomassa densa.

Penetração das Bandas




Figura: Interação das bandas X, C, L e P com a vegetação.

Polarização

- Descreve a orientação da onda eletromagnética.
- **H**: Polarização Horizontal.
- **V**: Polarização Vertical.
- O SAR pode transmitir e receber em diferentes polarizações para extrair mais informações.
- **Exemplos de canais:**
 - **HH**: Transmite H, Recebe H (co-polarizado).
 - **HV**: Transmite H, Recebe V (cruzado-polarizado).
 - **VV**: Transmite V, Recebe V (co-polarizado).
 - **VH**: Transmite V, Recebe H (cruzado-polarizado).

Tipos de Espalhamento Polarimétrico

A combinação de polarizações nos ajuda a entender como o sinal interagiu com o alvo.

- 1 **Espalhamento de Superfície:** Interação com superfícies ásperas. Dominante em canais **VV**.
- 2 **Espalhamento de Volume:** Múltiplas interações dentro de um meio complexo (ex: copa de árvores). Dominante em canais **cruzados (HV, VH)**.
- 3 **Espalhamento de Duplo Rebote:** Ocorre quando o sinal reflete em duas superfícies (ex: tronco-solo, parede-chão). Dominante em canais **HH**.

Exemplo de Duplo Rebote

Este mecanismo é muito útil para identificar estruturas verticais, como edifícios em áreas urbanas ou vegetação inundada.




Figura: Ilustração do espalhamento de duplo rebote em áreas urbanas e florestas.

Aplicações do SAR

A versatilidade do SAR permite seu uso em diversas áreas:

- **Agricultura:** Monitoramento de safras e umidade do solo.
- **Geologia e Geofísica:** Detecção de deformações no terreno (terremotos, vulcões) com InSAR.
- **Gerenciamento de Desastres:** Mapeamento de inundações, incêndios e desmatamento.
- **Oceanografia:** Monitoramento de gelo marinho, detecção de navios e derramamento de óleo.
- **Mapeamento e Planejamento Urbano:** Análise de estruturas e expansão urbana.

A Informação nos Pixels

- Uma imagem é formada por pixels.
- Em imagens de satélite, cada pixel contém a intensidade do sinal para diferentes **bandas** (ex: Vermelho, Verde, Infravermelho).
- Bandas próximas no espectro podem conter informações **redundantes** ou correlacionadas.
- **Pergunta:** Como podemos medir e analisar essa redundância?

A Matriz de Covariância

- É a ferramenta estatística para quantificar a relação linear entre as bandas.
- Captura a **variância** de cada banda e a **covariância** entre pares de bandas.

Uma matriz de covariância C para 3 bandas:

$$C = \begin{bmatrix} \text{Var}(\text{Banda 1}) & \text{Cov}(1,2) & \text{Cov}(1,3) \\ \text{Cov}(2,1) & \text{Var}(\text{Banda 2}) & \text{Cov}(2,3) \\ \text{Cov}(3,1) & \text{Cov}(3,2) & \text{Var}(\text{Banda 3}) \end{bmatrix}$$

Interpretando a Matriz de Covariância

- **Diagonal Principal (Variância):**

- Valor alto: grande variação de intensidade dos pixels naquela banda. Muita informação/contraste.

- **Fora da Diagonal (Covariância):**

- Valor alto (positivo ou negativo): alta correlação entre as duas bandas. **Alta redundância.**
- Valor próximo de zero: baixa correlação. As bandas são mais independentes.

Roteiro da Apresentação

- 1 Introdução ao SAR
 - Características do Sinal SAR
 - Mecanismos de Espalhamento
 - A Redundância em Imagens Multiespectrais
- 2 Análise de Componentes Principais (PCA)
- 3 A Imagem como Matriz de Dados
 - Manipulação com NumPy
 - Cuidados e Casos Especiais
 - Normalização e Qualidade da Imagem

O que é PCA?

- **Análise de Componentes Principais.**
- Técnica para **reduzir a dimensionalidade** de dados.
- Transforma as bandas originais (correlacionadas) em um novo conjunto de variáveis **não correlacionadas**, chamadas de Componentes Principais.
- O objetivo é manter o máximo de informação (variância) com o mínimo de componentes.

A Matemática por Trás do PCA

- O PCA se baseia na decomposição da matriz de covariância C .
- Encontramos os **autovalores** (λ) e **autovetores** (\mathbf{v}) que resolvem a equação:

$$(C - \lambda \mathbf{I})\mathbf{v} = 0$$

- **Autovetores** (\mathbf{v}): Apontam as direções de maior variância nos dados (as novas componentes principais).
- **Autovalores** (λ): Indicam a quantidade de variância que cada componente principal captura.
- `np.linalg.eigh(C)`

Interpretando os Resultados

Autovalores (λ)

- Representam a **importância** de cada componente.
- Quanto maior o autovalor, mais informação (variância) aquela componente retém.
- Permite ordenar as componentes da mais para a menos importante.

Autovetores (v)

- Definem as **novas direções**.
- Os valores dentro do autovetor são os **pesos** que indicam a contribuição de cada banda original para a nova componente.

Exemplo Prático de um Autovetor

$$v_1 = \begin{bmatrix} -0.733 \\ 0.677 \\ 0.071 \end{bmatrix}, \quad v_2 = \begin{bmatrix} 0.612 \\ 0.721 \\ -0.322 \end{bmatrix}, \quad v_3 = \begin{bmatrix} -0.64 \\ -0.71 \\ 0.27 \end{bmatrix}$$

- (v_1) : Captura o contraste entre a banda vermelho (-0.733) e as bandas verde (0.677) e infravermelho (0.071)
- (v_2) : Enfatiza a banda verde (0.721) e vermelho (0.612) com contraste negativo no infravermelho (-0.322)
- (v_3) : Reflete variações residuais com contribuições negativas no vermelho (-0.64) e verde (-0.71) e positiva no infravermelho (0.27).

Ortogonalidade das Componentes

- Uma propriedade fundamental do PCA é que os autovetores são **ortogonais** entre si.
- Isso significa que as Componentes Principais resultantes são **estatisticamente independentes** (não correlacionadas).
- A redundância foi eliminada!
- Matematicamente, se U é a matriz com os autovetores, então:

$$U^T U = I \quad (\text{Matriz Identidade})$$

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Resumo e Vantagens do PCA

O que o PCA nos permite fazer:

- 1 **Reduzir a dimensionalidade:** Manter 99% da informação usando, por exemplo, 3 componentes em vez de 10 bandas originais.
- 2 **Identificar padrões:** Revelar as relações e contrastes mais importantes nos dados.
- 3 **Melhorar a interpretação:** Transformar dados complexos e correlacionados em um conjunto mais simples e independente.

Roteiro da Apresentação

1

Introdução ao SAR

- Características do Sinal SAR
- Mecanismos de Espalhamento
- A Redundância em Imagens Multiespectrais

2

Análise de Componentes Principais (PCA)

3

A Imagem como Matriz de Dados

- Manipulação com NumPy
- Cuidados e Casos Especiais
- Normalização e Qualidade da Imagem

O que é uma Imagem Digital?

- No fundo, uma imagem é uma **matriz (ou tabela) de números**.
- Cada número é um **pixel** e representa a intensidade de luz ou reflectância.
- **Exemplo (tons de cinza):**
 - 0 = Preto total
 - 255 = Branco total

100	200	150
50	75	255

Mínimo e Máximo de uma Imagem

- **Mínimo:** O menor valor de pixel em toda a imagem.
- **Máximo:** O maior valor de pixel em toda a imagem.

Por que isso é útil?

- Para entender a **faixa de intensidades** (range dinâmico) da imagem.
- Para realizar ajustes, como o **estiramento de contraste**.

Exemplo

Uma imagem muito escura pode ter valores apenas entre 10 e 50. Ao saber disso, podemos "esticar" essa faixa para 0-255, melhorando os detalhes.

Como Encontrar Mínimos e Máximos?

- Usamos a biblioteca **NumPy**, otimizada para cálculos com matrizes.
- É extremamente mais rápido do que verificar pixel por pixel com loops.

```
import numpy as np

# Imagem representada como uma matriz NumPy
imagem = np.array([[100, 200, 150], [50, 75, 300]])

minimo = np.min(imagem)    # Resultado: 50
maximo = np.max(imagem)    # Resultado: 300

print(f"Minimo: {minimo}, Maximo: {maximo}")
```

Aplicação: Normalização de Contraste

- A normalização reescala os valores dos pixels para uma nova faixa (ex: 0 a 255).
- A fórmula é:

$$\text{novo valor} = \frac{(\text{valor} - \text{mínimo})}{(\text{máximo} - \text{mínimo})} \times 255$$

```
# Continuacao do codigo anterior...
imagem_norm = ((imagem-minimo)/(maximo-minimo)*255)
# Converte para inteiro de 8 bits (tipo comum de imagem)
imagem_norm = imagem_norm.astype(np.uint8)

print(imagem_norm)
# [[ 51 153 102]
#   [  0  25 255]]
```

Imagens Multiespectrais

- Imagens de satélite geralmente têm múltiplas **bandas** (Vermelho, Verde, Azul, Infravermelho, etc.).
- Podemos calcular o mínimo e máximo para **cada banda separadamente**.
- Em NumPy, isso é feito especificando o eixo ('axis') da operação.

```
# Imagem com 100x100 pixels e 3 bandas
img_multi = np.random.rand(100, 100, 3)

# min/max por banda, calculados nos eixos 0 e 1
min_banda = np.min(img_multi, axis=(0, 1))
max_banda = np.max(img_multi, axis=(0, 1))
```

Cuidado: Valores Inválidos (NaN)

- Algumas imagens podem ter pixels com valores inválidos (ex: 'NaN' - Not a Number) para áreas sem dados, como nuvens.
- Usar 'np.min()' ou 'np.max()' em dados com 'NaN' resultará em 'NaN'.
- **Solução:** Use as funções que ignoram 'NaN'.

```
imagem_com_nan = np.array([[1.0, 2.0, np.nan],  
                           [4.0, 5.0, 6.0]])  
  
# Funcoes que ignoram NaN  
minimo = np.nanmin(imagem_com_nan) # Resultado: 1.0  
maximo = np.nanmax(imagem_com_nan) # Resultado: 6.0
```

A Normalização Causa Perda de Qualidade?

A resposta curta é: **depende do que você faz em seguida.**

Não, porque...

- É uma **transformação linear**.
- A relação entre os pixels é **preservada**.
- Geralmente **melhora a qualidade visual** ao aumentar o contraste.

Sim, se...

- Houver uma **mudança no tipo de dado** para um de menor precisão.

O Risco da Perda de Precisão

- Dados de sensoriamento remoto podem ter alta precisão (ex: 16-bit, com 65.536 níveis de cinza).
- Imagens para visualização em tela usam baixa precisão (ex: 8-bit, com 256 níveis de cinza).

O problema: Ao converter de 'float' ou 'int16' para 'uint8' (`astype(np.uint8)`), valores são **arredondados**.

- Diferenças muito sutis entre pixels podem ser perdidas.
- Ex: 100.7 e 100.8 podem ambos virar 51 após a conversão.

Conclusão

Para **visualização**, a perda é insignificante. Para **análise científica**, onde a precisão é crítica, evite a conversão para 'uint8'.

Como Evitar Problemas?

- **Para análise científica:**

- Mantenha os dados em seu tipo original ('float' ou 'int16').
- Se normalizar, não converta para 'uint8'.

- **Sempre trate valores inválidos:**

- Use 'np.nanmin()' e 'np.nanmax()' se houver 'NaN's.

- **Considere alternativas:**

- Se houver valores extremos (outliers), a normalização por percentis (ex: usando o 2º e 98º) pode dar resultados melhores.

Referências I



ALASKA SATELLITE FACILITY.

Introduction to SAR.

https://hyp3-docs.asf.alaska.edu/guides/introduction_to_sar/, 2025, Accessed: 2025-07-05.



CANTY, M. J.

Image Analysis, Classification and Change Detection in Remote Sensing.

CRC Press, 2019.



CAPELLA SPACE.

SAR 101: An Introduction to Synthetic Aperture Radar.

<https://www.capellaspace.com/blog/sar-101-an-introduction-to-synthetic-aperture-radar>
2020, Accessed: 2025-07-05.

Referências II



NASA EARTHDATA.

SAR — Earthdata.

<https://www.earthdata.nasa.gov/learn/earth-observation-data-basics/sar>, 2025, Accessed: 2025-07-05.

Obrigado pela presença de todos!

`brunomendes@fisica.ufmt.br`